



UNIVERSIDAD  
**NACIONAL**  
DE COLOMBIA

# Datos no estructurados y representación de texto

De bases de datos textuales a características  
Módulo de Análisis de Datos de Texto · Clase 1 de 5

# El recorrido del módulo

En las próximas cinco clases pasaremos del texto crudo a entender cómo funciona la IA generativa, paso a paso. Cada clase resuelve una limitación de la anterior.

**1. Representar  
texto**

**2. Pesar y  
comparar**

**3. Significado  
(embeddings)**

**4. Contexto  
(atención)**

**5. Generación  
(LLMs)**

*Hoy empezamos por el principio: ¿qué son los datos no estructurados y cómo convertimos un texto en algo que una máquina pueda analizar?*

# Datos estructurados y no estructurados

# Dos mundos de datos

## Estructurados

- Elementos bien definidos y relaciones claras
- Filas y columnas (bases de datos relacionales)
- Requiere mucho trabajo recopilarlos y curarlos

## No estructurados

- No hay modelo predefinido de filas y columnas
- Texto, imágenes, audio, video
- Hay estructura, pero oculta: hay que extraerla

**Se estima que más del 95% de los datos generados hoy no están estructurados.** A menudo necesitamos usar datos heterogéneos para tomar decisiones.

# Minería de texto

## ¿De qué hablamos?

Extraer información útil del texto con algoritmos estadísticos. También llamada ***text mining***, ***text analytics*** o ***machine learning from text***.

Cada vez más popular por la ubicuidad del texto: la Web, las redes sociales, los correos, las bibliotecas digitales, los chats.

**Bibliotecas digitales:** material de investigación y libros.

**Noticias electrónicas:** difusión digital de noticias.

**La Web:** un vasto repositorio enriquecido con enlaces e información secundaria.

# ¿Cómo representar un documento de texto?

# Tokenización

## Primer paso

Partir el texto en unidades mínimas llamadas **tokens** (normalmente palabras).

"This is a sample"

↓ tokenización ↓

[ "This" ] [ "is" ] [ "a" ] [ "sample" ]


Cada variante de tokenización  
(¿separo signos? ¿números?  
¿nombres compuestos?)  
modifica el espacio de características.

# Normalización y palabras vacías


## Técnicas habituales:

- Expresiones regulares para extraer fechas, URLs, correos.
- Pasar todo a minúsculas (normalización).
- Detección de Entidades.
- Eliminar palabras vacías (stopwords): de, la, que, un, una...
- Stemming. Computer, computing, compute, computation.

**Ley de Zipf:** la frecuencia de un término es inversamente proporcional a su rango. Unas pocas palabras (de, la, que) son las más frecuentes... y las menos informativas.



¿Qué tan útiles son “de”, “la” o “que” para entender la semántica del texto?  
Guardemos esta idea para la próxima clase.

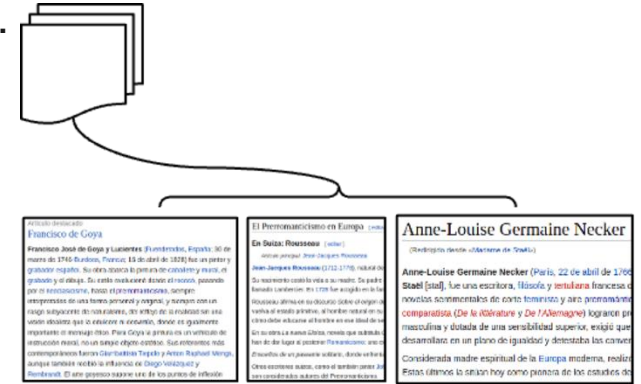




# Corpus, lexicón y bolsa de palabras

**Corpus:** un conjunto de documentos (páginas web, tweets, noticias...) en texto plano.

**Lexicón:** el conjunto completo de palabras distintas que aparecen en el corpus.



## Bolsa de palabras (Bag of Words)

- El orden de las palabras no importa: solo cuántas veces aparece cada una.
- Las palabras se tratan como dimensiones (features) y sus valores son las frecuencias de ocurrencia.
- Ejemplo (párrafo del tango, 57 palabras): “de” aparece 4 veces; “tango”, 2. Cada término es una característica del documento.

El tango revolucionó el baile popular introduciendo una danza sensual con pareja abrazada que propone una profunda relación e mociónal de cada persona con su propio cuerpo y de los cuerpos de los bailarines entre sí. Refiriéndose a esa relación, Enrique Santos Discépolo, uno de sus máximos poetas, definió al tango como «un pensamiento triste que se baila»

| Términos     | Frecuencia |
|--------------|------------|
| de           | 4/57       |
| tango        | 2          |
| los          | 2          |
| que          | 2          |
| una          | 2          |
| con          | 2          |
| el           | 1          |
| Santos       | 1          |
| si.          | 1          |
| danza        | 1          |
| relación     | 1          |
| al           | 1          |
| cada         | 1          |
| pensamiento  | 1          |
| sensual      | 1          |
| Refiriéndose | 1          |
| baile        | 1          |
| baila        | 1          |
| máximos      | 1          |
| relación     | 1          |
| sus          | 1          |
| esa          | 1          |
| Discépolo    | 1          |
| persona      | 1          |
| abrazada     | 1          |
| triste       | 1          |
| propone      | 1          |
| pareja       | 1          |
| cuerpo       | 1          |

# Matriz término-documento

Una forma de representar las palabras del texto como una tabla de números: **filas = documentos**, **columnas = términos**.

Las **filas de la matriz representan** las unidades de estudio (**los documentos**) de texto que se analizarán, y las **columnas de la matriz representan los términos** del texto que se utilizarán en el análisis.

|                                     | tango | baile | popular | vendido | sueños |
|-------------------------------------|-------|-------|---------|---------|--------|
| D1: El tango es un baile popular    | 1     | 1     | 1       | 0       | 0      |
| D4: Con el Tango líquido los sueños | 1     | 0     | 0       | 0       | 1      |
| D5: El Tango 01 fue vendido         | 1     | 0     | 0       | 1       | 0      |

**Características:** la mayoría de los valores son cero. Es una representación de alta dimensión, dispersa y no negativa.

# Representación documentos de texto

## Modelo de Bolsa de palabras

El **modelo de bolsa de palabras** es una técnica fundamental en el procesamiento del lenguaje natural (PLN) que se utiliza para representar documentos textuales de una manera que las máquinas puedan entender.

El orden de las palabras no importa

¿Cuál es la probabilidad de sacar la palabra "tango" de la bolsa?

En el contexto de un problema de aprendizaje las palabras se tratan como **dimensiones** (o features) y sus valores corresponden a las frecuencias de ocurrencia.




# Representación documentos de texto

## Palabras que no ayudan

- ❑ Modelos de bolsa de palabras: muchas palabras frecuentes no ayudan.
- ❑ Podemos remover esas palabras de la bolsa.
- ❑ Esos términos son llamados: **stopwords** o **palabras vacías**.
- ❑ Podemos utilizar listas de **stopwords** ya curadas para cada idioma.

un una unas unos uno sobre todo  
también tras otro algún alguno alguna  
algunos algunas ser es soy eres  
somos sois estoy esta estamos estais  
están como en para atrás porque por  
qué estado estaba ante antes siendo  
ambos pero por poder puede puedo  
podemos pueden fui fue fuimos  
fueron hacer hago hace hacemos  
hacen cada....



¿Qué tan útiles son estas palabras para entender la semántica?



# Stemming y lematización

## Stemming

- Corta la palabra a una raíz por heurística
- Rápido, pero la raíz puede no ser una palabra válida
- Corriendo, correr, corrida → "corr"

| Form             | Suffix | Stem  |
|------------------|--------|-------|
| stud <b>ies</b>  | -es    | studi |
| stud <b>ying</b> | -ing   | study |
| niñ <b>as</b>    | -as    | niñ   |
| niñ <b>ez</b>    | -ez    | niñ   |

|            |        |
|------------|--------|
| efectúa    | efectu |
| efectuaba  | efectu |
| efectuada  | efectu |
| efectuadas | efectu |
| efectuado  | efectu |
| efectúan   | efectu |
| efectuar   | efectu |
| efectuará  | efectu |
| efectuarán | efectu |
| efectuaría | efectu |
| efectuaron | efectu |
| efectuarse | efectu |
| efectúen   | efectu |
| efectuo    | efectu |
| efectúo    | efectu |
| efectuó    | efectu |

## Lematización

- Usa la categoría gramatical para hallar el lema
- Devuelve una palabra base válida. Depende del lugar del discurso y son altamente específicas del idioma.
- corriendo → "correr"

| Form     | Morphological information                                             | Lemma |
|----------|-----------------------------------------------------------------------|-------|
| studies  | Third person, singular number, present tense of the verb <b>study</b> | study |
| studying | Gerund of the verb <b>study</b>                                       | study |
| niñas    | Feminine gender, plural number of the noun <b>niño</b>                | niño  |
| niñez    | Singular number of the noun <b>niñez</b>                              | niñez |

Consideremos la palabra "corriendo".

Stemming: Podría reducirla a "corri", que no es una palabra válida.

Lematización: Identificaría "correr" como el lema, que es la forma base y válida de la palabra.

Ambos reducen la dimensionalidad: agrupan palabras de la misma familia en un solo término, simplificando la matriz.

# Frases como un solo término: entidades

El reconocimiento de entidades es una técnica fundamental dentro del procesamiento del lenguaje natural (PLN) que se encarga de identificar y clasificar elementos específicos dentro de un texto. Estos elementos, llamados entidades, pueden ser personas, organizaciones, ubicaciones, fechas, cantidades, etc.

¿Para qué sirve?

Imagina que tienes un montón de reseñas de productos. El reconocimiento de entidades te permitiría identificar automáticamente los nombres de los productos, las marcas y las opiniones de los usuarios. Esto sería muy útil para realizar análisis de sentimiento, estudios de mercado o para crear sistemas de recomendación.

**Reconocimiento de entidades (NER: Named Entity Recognition):** identificar y clasificar expresiones que refieren a personas, organizaciones, lugares, marcas, fechas o medidas. Es una subtarea de la extracción de información.

**Enrique Santos Discépolo    •    Buenos Aires    •    Santa Cruz**

**POS tagging (etiquetado morfosintáctico):** asignar a cada palabra su categoría gramatical (sustantivo, verbo, adjetivo...). Es un paso previo para muchas tareas de PLN.

# Representación documentos de texto

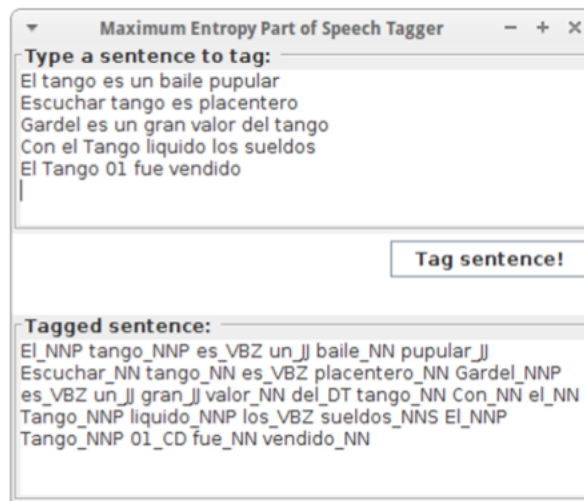
## Otras tareas del Procesamiento del Lenguaje Natural

**Part-of-speech tagging (Etiquetado morfosintáctico):** averiguar qué son sustantivos, verbos, adjetivos, etc.

El etiquetado morfosintáctico, también conocido como *Part-of-Speech tagging* (POS tagging), es una técnica fundamental en el procesamiento del lenguaje natural (PLN) que consiste en asignar a cada palabra de una oración una etiqueta que indica su categoría gramatical o parte del discurso. Estas categorías pueden ser sustantivos, verbos, adjetivos, adverbios, preposiciones, conjunciones, etc.

**¿Para qué sirve?**

- **Análisis sintáctico:** Es el primer paso para comprender la estructura gramatical de una oración y las relaciones entre las palabras.
- **Análisis semántico:** Ayuda a determinar el significado de las palabras en el contexto de una oración.
- **Otras tareas de PLN:** Es una tarea previa necesaria para muchas otras aplicaciones de PLN, como la traducción automática, el resumen de textos, la generación de lenguaje natural y el análisis de sentimientos.



El **\_NNP** tango **\_NNP** es **\_VBZ** un **\_JJ**  
baile **\_NN** popular **\_JJ** Escuchar **\_NN**  
tango **\_NN** es **\_VBZ** placentero **\_NN**  
Gardel **\_NNP** es **\_VBZ** un **\_JJ** gran **\_JJ**  
valor **\_NN** del **\_DT** tango **\_NN** Con **\_NN**  
el **\_NN** Tango **\_NNP** liquido **\_NNP** los **\_VBZ**  
sueños **\_NNN** El **\_NNP** Tango **\_NNP**  
01 **\_CD** fue **\_NN** vendido **\_NN**



# Lo que sigue

Ya convertimos texto en una matriz de frecuencias. **Pero...**

**en esa matriz “de” aparece más que “tango”. La frecuencia cruda no mide importancia.**

*En la próxima clase: cómo pesar las palabras (TF-IDF) y comparar documentos.*



# Laboratorio · Clase 1

## Notebook — Representación de texto

- Cargar un corpus pequeño en español (titulares o tweets) con pandas.
- Tokenizar, pasar a minúsculas y quitar stopwords con nltk.
- Aplicar stemming (SnowballStemmer en español) y comparar con el texto original.
- Construir la matriz término-documento con CountVectorizer de scikit-learn.
- Visualizar la frecuencia de términos y comprobar empíricamente la Ley de Zipf.

Stack: Python · pandas · nltk · scikit-learn · matplotlib