



UNIVERSIDAD  
**NACIONAL**  
DE COLOMBIA

# Pesar términos y comparar documentos

TF-IDF, espacio vectorial y similitud coseno  
Módulo de Análisis de Datos de Texto · Clase 2 de 5

# ¿Dónde quedamos y qué nos faltaba?

En la clase 1 convertimos texto en una **matriz término-documento**: cada documento es una fila, cada término una columna, las celdas guardan frecuencias.

**El problema:** “de” aparecía 4 veces y “tango” solo 2. La frecuencia cruda no mide importancia, y las stopwords eran apenas un parche binario. Necesitamos algo gradual.

**Contar no es valorar.  
Hoy: pesar las palabras  
y comparar documentos.**

# TF-IDF

# Frecuencia de término (TF)

## Definición

**TF** mide qué tan seguido aparece un término  $t$  en un documento  $d$ .

### Variantes habituales:

- Conteo crudo: número de ocurrencias de  $t$  en  $d$ .
- Frecuencia relativa:  $\text{ocurrencias} \div \text{total de palabras de } d$ .
- Log-normalizada:  $1 + \log(\text{conteo})$ , para amortiguar conteos altos.

Es la “fracción de tango en el párrafo” que vimos en la bolsa de palabras.

# Frecuencia inversa de documento (IDF)

Una palabra que aparece en **todos** los documentos no sirve para distinguirlos. Una palabra rara, en cambio, es muy informativa.

$$\text{idf}(t) = \log ( N / \text{df}(t) )$$

$N$  = número total de documentos    ·     $\text{df}(t)$  = documentos que contienen  $t$

**Conexión con la Ley de Zipf (clase 1):** las pocas palabras muy frecuentes son justamente las menos informativas. IDF las penaliza de forma natural — es la versión gradual de quitar stopwords.

# TF-IDF: el producto

$$\text{tfidf}(t, d) = \text{tf}(t, d) \times \text{idf}(t)$$

Alto cuando el término es frecuente en este documento pero raro en el corpus: cuando es característico de ese documento.

## Sobre el corpus de juguete

“tango” aparece en los 5 documentos  $\rightarrow df = 5 \rightarrow idf = \log(5/5) = 0$ .

**¡Pese a ser el tema, su peso TF-IDF es nulo porque no distingue documentos!**

“Gardel”, “sueldos”, “vendido” aparecen en 1 solo documento  $\rightarrow$  IDF alto  $\rightarrow$  caracterizan a su texto.

# Documentos como vectores

# Similitud coseno

Cada documento es un vector de pesos TF-IDF. Para comparar dos documentos no medimos su distancia (la longitud del texto distorsiona), sino el **ángulo** entre sus vectores.

$$\text{sim}(A, B) = \cos(\theta) = (A \cdot B) / (\|A\| \|B\|)$$

Vale 1 si apuntan en la misma dirección, 0 si son ortogonales. Ignora el tamaño del documento.

## Coseno

Sobre pesos TF-IDF  
(vectores con magnitud)

## Jaccard

Sobre presencia/ausencia  
(conjuntos binarios de términos)



# Aplicación: buscar y detectar duplicados

## Un buscador minúsculo

1. Vectorizar la consulta con el mismo esquema TF-IDF.
2. Calcular la similitud coseno entre la consulta y cada documento.
3. Ordenar de mayor a menor similitud y devolver los primeros.

**Detección de plagio / casi-duplicados:** dos documentos con similitud coseno por encima de un umbral son sospechosos de compartir contenido. La misma idea sirve para agrupar noticias repetidas.

# Lo que sigue

**El espacio vectorial funciona, pero...**

**“tango” y “milonga” son dimensiones totalmente independientes: el modelo no sabe que están relacionadas.**

*¿Y si las palabras tuvieran coordenadas que reflejen su significado? Próxima clase: word embeddings.*

# Laboratorio · Clase 2

## Notebook — TF-IDF y similitud

- Construir la matriz TF-IDF con `TfidfVectorizer` y verificar que coincide con el cálculo a mano sobre el corpus de juguete.
- Identificar los términos de mayor TF-IDF por documento (“palabras características”).
- Implementar un buscador por similitud coseno sobre el corpus de noticias.
- Matriz de similitud documento-documento + heatmap; detectar casi-duplicados por umbral.

Stack: Python · pandas · scikit-learn · matplotlib