



UNIVERSIDAD
NACIONAL
DE COLOMBIA

Significado por contexto

Word embeddings: de dimensiones dispersas a vectores densos
Módulo de Análisis de Datos de Texto · Clase 3 de 5

¿Dónde quedamos y qué nos faltaba?

Ya comparamos documentos con similitud coseno sobre vectores TF-IDF. Pero esos vectores tienen un problema profundo de **significado**.

El problema concreto: los vectores de “perro” y “gato” son ortogonales (similitud 0), igual que “perro” y “avión”. La representación no captura que perro y gato son cercanos.

Cada palabra es una dimensión aislada. No hay noción de que dos palabras se parezcan.

La hipótesis distribucional

“Conocerás una palabra por su compañía”

Hipótesis distribucional

Las palabras que aparecen en contextos parecidos tienden a significar cosas parecidas. “Café” y “té” aparecen rodeadas de palabras similares (beber, taza, caliente, mañana).

La idea es la misma intuición que usaron NER y POS tagging: el contexto define el rol y el sentido de una palabra. Aquí la llevamos un paso más allá: el contexto define su **significado completo**, y lo codificamos como un vector.

De vectores dispersos a vectores densos

TF-IDF (disperso)

- Miles de dimensiones (una por término)
- Casi todo ceros
- Sin relación entre dimensiones

Embedding (denso)

- 100–300 dimensiones
- Valores continuos, todos usados
- Dimensiones latentes que capturan significado

Es una reducción de dimensionalidad. El mismo principio del SVD / factorización de matrices que vieron en filtrado colaborativo: dimensiones latentes que capturan estructura oculta de los datos.

word2vec: aprender significado

Dos formas de mirar lo mismo

CBOW: predecir una palabra a partir de su contexto.

Skip-gram: predecir el contexto a partir de una palabra.

La propiedad que sorprende:

los vectores aprenden relaciones semánticas que se pueden operar como aritmética.

$$\text{rey} - \text{hombre} + \text{mujer} \approx \text{reina}$$

¿Y cómo medimos si dos embeddings son parecidos?
Con similitud coseno —
la misma de la clase 2.

Lo que sigue

Los embeddings capturan significado... pero estático.

“Banco” (para sentarse) y “banco” (financiero) colapsan en el mismo vector, sin importar la frase.

Necesitamos representaciones que dependan del contexto completo. Próxima clase: atención y Transformers.

Laboratorio · Clase 3

Notebook — Embeddings (demostrativo)

- Aplicar TruncatedSVD de scikit-learn a la matriz TF-IDF para obtener dimensiones latentes e ilustrar la idea de embedding sin entrenar word2vec.
- Visualizar documentos/términos en 2D (PCA o SVD) y observar agrupamientos semánticos.
- Comparar la similitud coseno en el espacio latente vs. el espacio TF-IDF original de la clase 2.
- Discusión: por qué el espacio reducido relaciona palabras que antes eran ortogonales.

Stack: Python · pandas · scikit-learn (TruncatedSVD, PCA) · matplotlib